基于改进 CNN 的 CIFAR-10 图像分类

姓名/学号：李俐彤/10245501415

GitHub 仓库链接：https://github.com/lilitong1027/AI-Experiments/tree/main/Experiment-3

摘要

本实验基于 PyTorch 框架，独立设计并实现了一个包含 BatchNorm 与全局平均池化（GAP）的卷积神经网络（CNN），用于 CIFAR-10 数据集的图像分类任务。通过引入随机裁剪、随机翻转等数据增强策略，结合 StepLR 学习率衰减与早停机制，有效抑制了过拟合。最终模型在测试集上取得了 **90.18%**的准确率，并针对混淆矩阵与误分类样本进行了深入的误差分析。

1. 数据集与数据增强

CIFAR-10 包含 10 类共 60,000 张 32×32 的彩色图像。本实验将 50,000 张训练集按 8:2 **分层抽样**划分为训练集与验证集（确保各类别比例一致），10,000 张测试集用于最终评估。
为提升模型泛化能力，训练阶段引入了两种数据增强：

- **RandomCrop(32, padding=4)**：填充后随机裁剪，提升模型对平移的鲁棒性。
- **RandomHorizontalFlip**：随机水平翻转，增加样本多样性。
  验证集与测试集仅进行 ToTensor 与 Normalize 标准化（均值 0.5，标准差 0.5）。

2. 模型结构设计

本模型采用了包含 3 个卷积块（Block）的自定义 CNN 网络，具体设计如下：

1. **特征提取层**：每个 Block 包含两个 3×3 卷积层（padding=1），每次卷积后紧接 **BatchNorm** 与 ReLU 激活，最后通过 2×2 最大池化降维。通道数依次递增（64 -> 128 -> 256）。
2. **分类头**：使用**全局平均池化（GAP）**代替传统 Flatten 操作，大幅减少参数量并防止过拟合；随后接入丢弃率（Dropout）为 0.5 的全连接层，最终输出 10 维分类结果。

3. 训练策略与实验设置

- **损失函数**：交叉熵损失（CrossEntropyLoss）。
- **优化器**：SGD（Momentum=0.9，Weight Decay=5e-4，初始学习率 0.1）。
- **学习率调度**：采用 StepLR，每 15 个 epoch 学习率衰减为原来的 0.1。

- **早停机制**：设置 Patience=15。当验证集准确率连续 15 个 epoch 不再提升时自动停止训练，并保存最佳权重。

4. 实验结果与可视化分析

模型在训练至第 47 个 epoch 时触发早停，最终在测试集上的准确率为 **90.18%**。

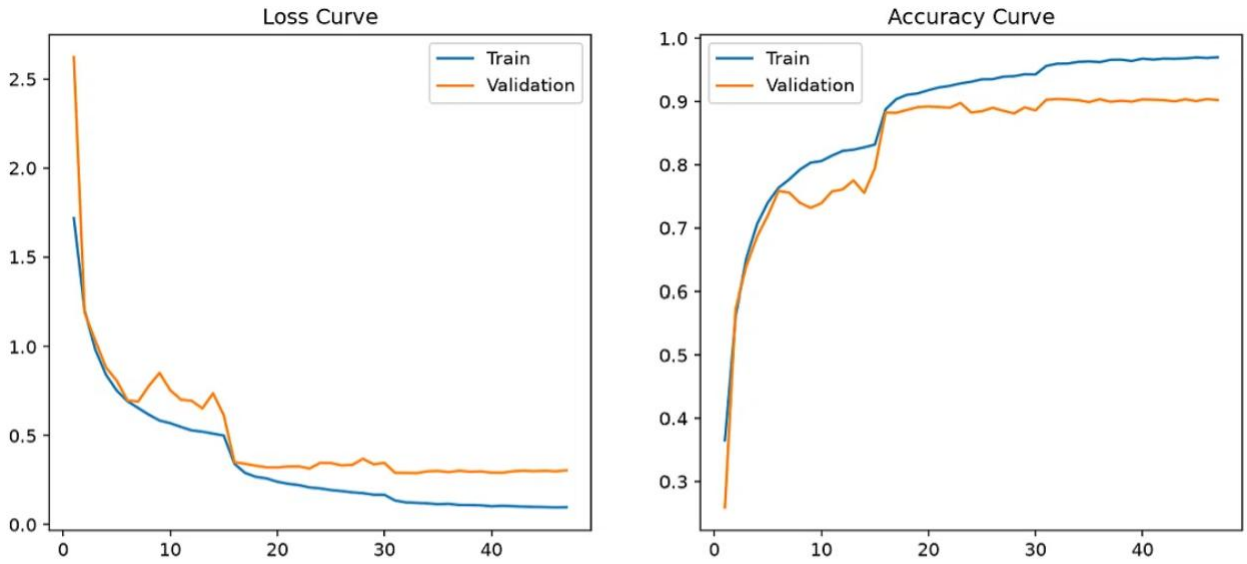


图 1：训练过程 Loss 与 Accuracy 曲线

分析：由图 1 可见，在第 15 个和第 30 个 epoch（学习率衰减点），Loss 曲线出现阶梯式下降，准确率显著跃升。训练集最终准确率约 97%，验证集稳定在 90%。两者存在轻微差距，表明模型具备较强拟合能力，但也存在一定过拟合，早停机制有效避免了后期验证集性能退化。

=== 各类别分类报告 ===

	precision	recall	f1-score	support
airplane	0.9000	0.9180	0.9089	1000
automobile	0.9427	0.9700	0.9561	1000
bird	0.8851	0.8470	0.8656	1000
cat	0.8047	0.7950	0.7998	1000
deer	0.8974	0.9100	0.9037	1000
dog	0.8553	0.8450	0.8501	1000
frog	0.9157	0.9340	0.9248	1000
horse	0.9307	0.9270	0.9289	1000
ship	0.9427	0.9370	0.9398	1000
truck	0.9406	0.9350	0.9378	1000
accuracy			0.9018	10000
macro avg	0.9015	0.9018	0.9015	10000
weighted avg	0.9015	0.9018	0.9015	10000

表 1：各类别分类报告（Classification Report）

分析：交通工具类（automobile 97%, ship 93.7%, truck 93.5%）的召回率极高，说明几何

特征明显的物体易于识别；而动物类（cat 79.5%, bird 84.7%）的准确率相对较低。

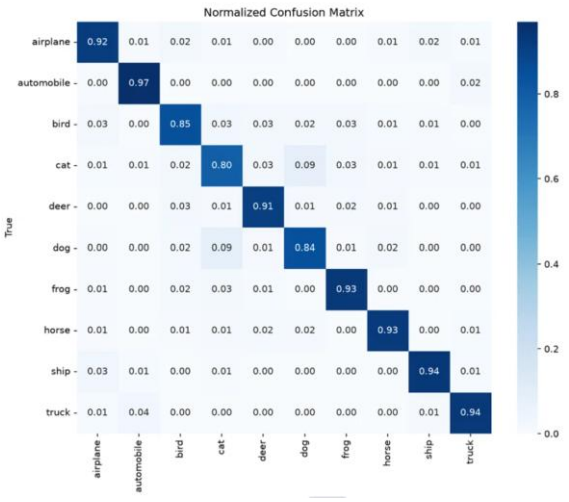


图 2：归一化混淆矩阵

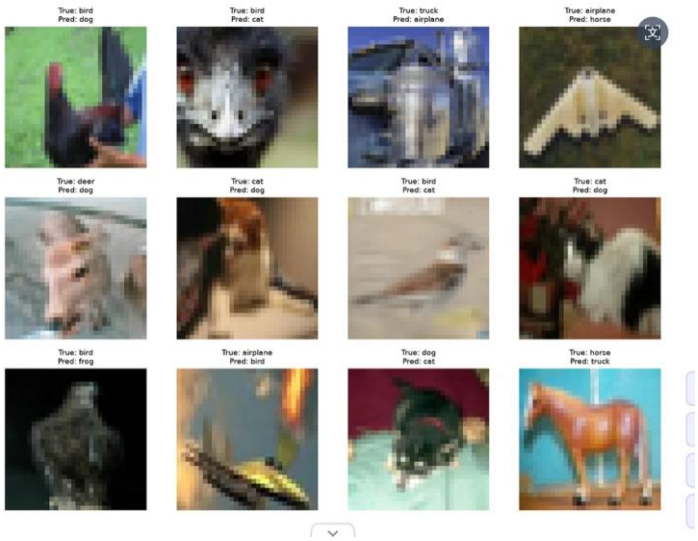


图 3：误分类样本可视化

5. 误差分析与独立思考

结合混淆矩阵（图 2）与误分类样本（图 3），模型的主要误差来源于：

1. **纹理与分辨率瓶颈（猫狗混淆）**：混淆矩阵显示，9%的猫被误判为狗，9%的狗被误判为猫。在 32×32 极低分辨率下，猫狗的面部轮廓和毛发纹理高度相似。例如图 3 中，一只猫被认成狗，肉眼也难以分辨其五官特征。
2. **背景干扰（鸟类误判）**：有部分鸟被误判为飞机（3%）或鹿（3%）。观察图 3 发现，部分鸟类样本处于蓝天背景中，且姿态呈展翅状，模型可能过度依赖了“蓝天”背景特征而非主体特征；另一张图将飞机预测为马，也是因为机身颜色与草地/动物颜色相近。

3. **主观模糊样本**：部分样本（如图 3 中类似狗的图被标为 deer）属于数据集自身标注模糊或图像严重遮挡，即便人类也难以正确分类。

改进方案：
本实验的训练策略（数据增强+早停+学习率衰减）成功将准确率推至 90%以上。若要进一步突破，未来可引入 **CutMix/Mixup** 增强，强迫模型学习局部特征；或在模型中引入**注意力机制（如 SE-Block）**，使模型更加聚焦图像主体，减少背景干扰。

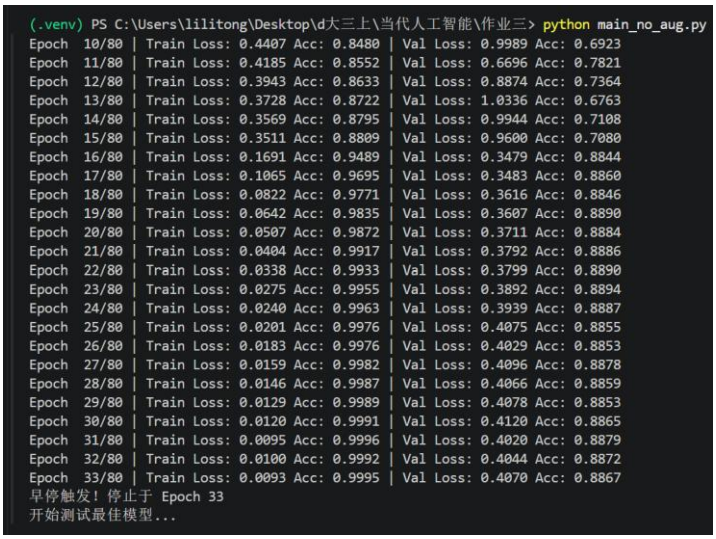
6.对比实验

1. 数据增强对比实验

为了验证数据增强策略的有效性，本实验在完全相同的网络结构、优化器和早停策略下，对比了“包含数据增强”与“无数据增强”两种训练方式。

实验配置	训练集准确率	验证集准确率	验证集 Loss 变化	训练现象分析
完整模型（含增强）	约 97.0%	90.18% (测试集)	持续下降并稳定于 0.30	泛化能力强，收敛平稳。
消融模型（无增强）	99.95% (极度过拟合)	约 88.6%	第 16 轮后反弹上升 (0.34 升至 0.41)	死记硬背了训练集特征，泛化能力差。

3. 数据分析与结论



从日志数据中可以看到，移除数据增强后，模型在第 16 个 Epoch 时训练准确率就飙

升到了 94.89%，到第 33 个 Epoch 更是达到了 99.95%。
然而，此时验证集准确率却停滞在 88.6% 左右，且验证集 Loss 从 0.34 反向上升到了 0.41。这是非常典型的过拟合特征：模型开始过度拟合训练集中的高频细节（如特定的背景颜色、特定角度的轮廓），对未见过的数据丧失了泛化能力。

结论：在未使用数据增强时，模型虽然能在训练集上达到近乎完美的拟合（99.95%），但在验证集上表现受限。而引入 RandomCrop 和 RandomHorizontalFlip 后，有效地充当了正则化手段，打破了图像中的空间相关性，迫使模型学习更本质、更鲁棒的特征，最终将测试集准确率稳定推高到了 90.18%。

7. 结论

本实验独立完成了从模型设计到评估的全过程。通过合理设计 CNN 架构与优化策略，CIFAR-10 分类准确率达到了 90.18%。实验证明了 BatchNorm 与数据增强在深度网络中的关键作用，并通过详实的误差分析，为后续模型改进指明了方向。